



UNIVERSIDAD PRIVADA DEL VALLE
FACULTAD DE INGENIERIA DE SISTEMAS
INFORMATICOS CAMPUS TIQUIPAYA

PREDICCION DE RIESGO DE ACCIDENTES CEREBRO VASCULAR MEDIANTE REDES NEURONALES

Matéria: Tecnologías Emergentes I

Docente: Ing. Efrain Luna Mamani

Estudiantes: Marco Michel Salas Justiniano

Manuel Augusto Ovando Crespo

Dataset: healthcare-dataset-stroke-data

Fecha: 15/06/2026

1.	INTRODUCCIÓN	4
2.	DESCRIPCIÓN DEL DATASET	5
2.1.	Fuente de los datos	5
2.2.	Tamaño del Dataset.....	5
2.3.	Variables del Dataset.....	5
2.4.	Distribución de la variable objetivo	5
2.5.	Variables demográficas y clínicas.....	6
3.	ANÁLISIS EXPLORATORIO DE DATOS (EDA)	7
3.1.	Análisis de Valores Faltantes (Nulos)	7
3.2.	Distribución de la Variable Objetivo (`stroke`)	7
3.3.	Distribución de Variables Categóricas	7
3.4.	Distribución de Variables Numéricas Continuas	9
3.5.	Relación de Variables Numéricas con Stroke (Boxplots)	9
3.6.	Análisis de Correlación	9
4.	PREPROCESAMIENTO	10
4.1.	Filtrado de registros inconsistentes	10
4.2.	Imputación de valores nulos	10
4.3.	Codificación de variables categóricas (Encoding).....	10
4.4.	División en conjuntos de entrenamiento y prueba	10
4.5.	Estandarización de variables numéricas (Scaling).....	10
4.6.	Balanceo de clases mediante SMOTE	11
5.	FUNDAMENTO TEÓRICOS	11
5.1.	Neurona Artificial	11
5.2.	Función de activación ReLU.....	11
5.3.	Función Sigmoide.....	12
5.4.	Función de pérdida (Binary Cross Entropy)	12
5.5.	Descenso por Gradiente (Gradient Descent).....	12
5.6.	Optimizador Adam.....	13
6.	PROCESO DE ENTRENAMIENTO.....	13
7.	HIPERPARÁMETROS CLAVE Y SU IMPACTO	14
7.1.	Impacto de los hiperparámetros	14
7.2.	Ventajas, Limitaciones y Casos de Uso Reales	14
8.	IMPLEMENTACIÓN	15
8.1.	Librerías Utilizadas:	15
8.2.	Hiperparámetros Elegidos:	15
8.3.	Decisiones de Diseño:.....	15

9.	MODELO COMPARATIVO	15
10.	RESULTADOS	16
10.1.	F1-score & Accuracy	16
10.2.	matriz de confusión	16
10.3.	Curva ROC.....	17
11.	ANÁLISIS E INTERPRETACIÓN.....	17
12.	CONCLUSIONES	18
12.1.	Limitaciones	19
12.2.	Posibles Mejoras.....	19

1. INTRODUCCIÓN

Los accidentes cerebrovasculares (Stroke) constituyen una de las principales causas de muerte y discapacidad a nivel mundial, representando un importante problema de salud pública debido a sus graves consecuencias físicas, cognitivas y económicas. Esta enfermedad ocurre cuando el flujo sanguíneo hacia una parte del cerebro se interrumpe o disminuye, provocando daños en las células cerebrales que pueden derivar en secuelas permanentes o incluso en la muerte del paciente. Debido a su impacto en la calidad de vida de las personas y en los sistemas de salud, la identificación temprana de individuos con alto riesgo de sufrir un accidente cerebrovascular se ha convertido en una prioridad para la medicina preventiva.

La detección oportuna de factores de riesgo asociados al Stroke permite implementar medidas preventivas, realizar un seguimiento médico adecuado y promover cambios en los hábitos de vida de los pacientes. Variables como la edad, la hipertensión arterial, las enfermedades cardíacas, los niveles elevados de glucosa y otros factores clínicos han demostrado estar estrechamente relacionados con la probabilidad de desarrollar esta condición. Sin embargo, analizar simultáneamente múltiples variables y determinar su influencia en el riesgo de un paciente puede resultar una tarea compleja mediante métodos tradicionales.

En los últimos años, el avance de la inteligencia artificial y del aprendizaje automático ha permitido desarrollar herramientas capaces de analizar grandes volúmenes de datos médicos y descubrir patrones que podrían pasar desapercibidos para los especialistas. Dentro de estas técnicas, las Redes Neuronales Artificiales han demostrado una gran capacidad para modelar relaciones complejas entre variables, logrando resultados destacados en tareas de clasificación y predicción en el ámbito de la salud. Asimismo, algoritmos como XGBoost se han consolidado como una de las alternativas más eficientes para el análisis de datos tabulares debido a su alto rendimiento y capacidad de generalización.

El presente proyecto tiene como objetivo desarrollar un modelo de predicción de riesgo de accidente cerebrovascular utilizando información demográfica y clínica de pacientes. Para ello, se empleará una Red Neuronal Artificial como modelo principal, aprovechando su capacidad para aprender patrones complejos presentes en los datos. Adicionalmente, se implementará XGBoost como modelo comparativo con el fin de evaluar diferencias de rendimiento y determinar cuál ofrece mejores resultados para este problema de clasificación.

Finalmente, ambos modelos serán entrenados y evaluados utilizando métricas ampliamente utilizadas en problemas de clasificación binaria, tales como Accuracy, Precision, Recall, F1-Score y ROC-AUC. Estas métricas permitirán medir de manera objetiva la capacidad de los modelos para identificar correctamente a los pacientes con riesgo de sufrir un accidente

cerebrovascular, proporcionando información valiosa sobre su utilidad como herramientas de apoyo para la toma de decisiones en entornos clínicos.

2. DESCRIPCIÓN DEL DATASET

El conjunto de datos utilizado en este proyecto corresponde al **Healthcare Stroke Dataset**, disponible en la plataforma Kaggle. Este dataset reúne información demográfica y clínica de pacientes con el propósito de analizar los factores asociados al riesgo de sufrir un accidente cerebrovascular (stroke) y desarrollar modelos predictivos basados en aprendizaje automático.

2.1. Fuente de los datos

- Nombre **del dataset**: Healthcare Stroke Dataset
- Plataforma: Kaggle
- Tipo **de problema**: Clasificación binaria
- Variable **objetivo**: stroke

2.2. Tamaño del Dataset

El conjunto de datos está compuesto por **5.110 registros** de pacientes y **12 variables**, incluyendo la variable objetivo. Cada registro representa la información médica y demográfica de un individuo.

2.3. Variables del Dataset

Las variables incluidas en el conjunto de datos son las siguientes:

Variable	Tipo	Descripción
Id	Numérica	Identificador único del paciente
Gender	Categórica	Genero del paciente
Age	Numérica	Edad del paciente
Hypertension	Binaria	Indica si el paciente presenta hipertensión (0 = No, 1 = Sí)
heart_disease	Binaria	Indica si el paciente presenta enfermedad cardíaca (0 = No, 1 = Sí)
ever_married	Categórica	Estado civil del paciente
work_type	Categórica	Tipo de ocupación o trabajo
Residence_type	Categórica	Tipo de residencia (urbana o rural)
avg_glucose_level	Numérica	Nivel promedio de glucosa en sangre
bmi	Numérica	Índice de masa corporal (Body Mass Index)
smoking_status	Categórica	Estado de consumo de tabaco
stroke	Binaria	Variable objetivo que indica la ocurrencia de accidente cerebrovascular

2.4. Distribución de la variable objetivo

La variable objetivo stroke es de naturaleza binaria y representa la presencia o ausencia de un accidente cerebrovascular:

- **0:** El paciente no presentó accidente cerebrovascular.
- **1:** El paciente presentó accidente cerebrovascular.

Durante el análisis exploratorio se observó una distribución desbalanceada entre las clases, donde la mayoría de los registros corresponden a pacientes sin antecedentes de stroke. Esta característica hace necesario aplicar técnicas de balanceo de datos, como SMOTE, para mejorar el desempeño de los modelos predictivos y evitar sesgos hacia la clase mayoritaria.

2.5. Variables demográficas y clínicas

Las variables pueden agruparse en dos categorías principales:

Variables demográficas:

- Género (gender)
- Edad (age)
- Estado civil (ever_married)
- Tipo de trabajo (work_type)
- Tipo de residencia (Residence_type)


Variables clínicas:

- Hipertensión (hypertension)
- Enfermedad cardíaca (heart_disease)
- Nivel promedio de glucosa (avg_glucose_level)
- Índice de masa corporal (bmi)
- Estado de fumador (smoking_status)


Estas características proporcionan información relevante para identificar patrones asociados al riesgo de accidente cerebrovascular y constituyen la base para el entrenamiento de los modelos de clasificación desarrollados en este proyecto.

3. ANÁLISIS EXPLORATORIO DE DATOS (EDA)








3.1. Análisis de Valores Faltantes (Nulos)




3.2. Distribución de la Variable Objetivo (`stroke`)




3.3. Distribución de Variables Categóricas




3.4. Distribución de Variables Numéricas Continuas



3.5. Relación de Variables Numéricas con Stroke (Boxplots)



3.6. Análisis de Correlación



4. PREPROCESAMIENTO

Preprocesamiento de Datos

Antes del entrenamiento de los modelos, se realizó un proceso de preprocesamiento con el objetivo de mejorar la calidad de los datos y garantizar un adecuado desempeño de los algoritmos de aprendizaje automático.

4.1. Filtrado de registros inconsistentes

Se realizó una revisión inicial del conjunto de datos para identificar posibles registros inconsistentes o categorías poco representativas. En particular, se verificó la calidad de los datos y se eliminaron variables que no aportaban valor predictivo, como el identificador único del paciente (id), debido a que no contiene información relevante para la clasificación.

4.2. Imputación de valores nulos

Durante el análisis exploratorio se identificaron valores faltantes en la variable bmi (Índice de Masa Corporal). Para preservar la mayor cantidad posible de registros, los valores nulos fueron reemplazados mediante la mediana de la variable, ya que esta medida es menos sensible a valores extremos que la media.

4.3. Codificación de variables categóricas (Encoding)

Las variables categóricas fueron transformadas a formato numérico mediante la técnica **One-Hot Encoding**, permitiendo que los algoritmos de aprendizaje automático pudieran procesarlas correctamente. Las variables transformadas fueron:

- gender
- ever_married
- work_type
- Residence_type
- smoking_status

4.4. División en conjuntos de entrenamiento y prueba

El conjunto de datos fue dividido utilizando una proporción de:

- 80% para entrenamiento
- 20% para prueba

La división se realizó de forma estratificada respecto a la variable objetivo (stroke) para mantener la misma proporción de clases en ambos conjuntos.

4.5. Estandarización de variables numéricas (Scaling)

Las variables numéricas fueron normalizadas mediante **StandardScaler**, transformando cada variable para que tenga media cero y desviación estándar

igual a uno. Este proceso es especialmente importante para la Red Neuronal Artificial, ya que facilita la convergencia del algoritmo de optimización durante el entrenamiento.

4.6. Balanceo de clases mediante SMOTE

Debido al fuerte desbalance observado en la variable objetivo, se aplicó la técnica **SMOTE (Synthetic Minority Over-sampling Technique)** únicamente sobre el conjunto de entrenamiento. Esta técnica genera ejemplos sintéticos de la clase minoritaria (stroke), permitiendo equilibrar la distribución de clases y mejorar la capacidad del modelo para detectar pacientes con riesgo de accidente cerebrovascular.

Como resultado, se obtuvo un conjunto de entrenamiento balanceado, reduciendo el sesgo hacia la clase mayoritaria y mejorando métricas importantes como Recall y F1-Score.

5. FUNDAMENTO TEÓRICOS

5.1. Neurona Artificial

La neurona artificial es la unidad básica de una red neuronal. Su función consiste en recibir múltiples entradas, asignarles pesos y combinarlas para producir una salida.

$$z = \sum_{i=1}^n w_i x_i + b$$

Explicación:

Donde x_i representa las variables de entrada, w_i son los pesos asociados a cada entrada y b corresponde al sesgo (bias). Esta operación calcula una combinación lineal de las entradas que posteriormente será procesada por una función de activación.

5.2. Función de activación ReLU

La función ReLU (Rectified Linear Unit) es una de las funciones de activación más utilizadas en redes neuronales debido a su simplicidad y eficiencia computacional.

$$ReLU(x) = \max(0, x)$$

Explicación:

La función devuelve el mismo valor de entrada cuando este es positivo y devuelve cero cuando el valor es negativo. Esto permite introducir no linealidad en la red neuronal y facilita el aprendizaje de patrones complejos.

5.3. Función Sigmoid

La función sigmoide se utiliza en la capa de salida para problemas de clasificación binaria.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Explicación:

Transforma cualquier valor real en una probabilidad comprendida entre 0 y 1. En este proyecto, dicha probabilidad representa la posibilidad de que un paciente sufra un accidente cerebrovascular.

5.4. Función de pérdida (Binary Cross Entropy)

La función de pérdida mide la diferencia entre las predicciones realizadas por el modelo y los valores reales observados.

$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Explicación:

Esta función penaliza las predicciones incorrectas realizadas por el modelo. Cuanto menor sea el valor de la pérdida, mejor será la capacidad predictiva de la red neuronal. Es la función más utilizada en problemas de clasificación binaria.

5.5. Descenso por Gradiente (Gradient Descent)

El descenso por gradiente es el algoritmo utilizado para actualizar los pesos de la red neuronal durante el entrenamiento.

$$w_{new} = w - \eta \frac{\partial L}{\partial w}$$

Explicación:

La fórmula indica cómo se ajustan los pesos de la red en cada iteración. El parámetro η representa la tasa de aprendizaje (learning rate), mientras que el gradiente $\frac{\partial L}{\partial w}$ indica la dirección en la que debe modificarse el peso para reducir el error y mejorar las predicciones del modelo.


5.6. Optimizador Adam

El optimizador Adam (Adaptive Moment Estimation) fue utilizado para entrenar la red neuronal debido a su capacidad para ajustar automáticamente la tasa de aprendizaje durante el proceso de entrenamiento.

Explicación:

Adam combina las ventajas del descenso por gradiente con técnicas de adaptación de la tasa de aprendizaje, permitiendo una convergencia más rápida y estable. Por esta razón es uno de los optimizadores más utilizados en aplicaciones de Deep Learning.

6. PROCESO DE ENTRENAMIENTO



7. HIPERPARÁMETROS CLAVE Y SU IMPACTO

Hiperparámetro Valor		Impacto
Dense Layer 1	32 neuronas	Permite capturar patrones complejos en los datos
Dense Layer 2	16 neuronas	Reduce gradualmente la dimensionalidad
Dense Layer 3	8 neuronas	Extrae características más específicas
Dropout	0.2	Reduce el sobreajuste
Batch Size	32	Equilibrio entre velocidad y estabilidad
Epochs	50	Número máximo de iteraciones
Optimizer	Adam	Mejora la convergencia
Learning Rate	Automático (Adam)	Ajuste dinámico durante entrenamiento

7.1. Impacto de los hiperparámetros

- Un mayor número de neuronas puede aumentar la capacidad de aprendizaje, pero también el riesgo de sobreajuste.
- Dropout ayuda a mejorar la generalización.
- Adam acelera la convergencia del entrenamiento.
- EarlyStopping evita entrenar más allá del punto óptimo.

7.2. Ventajas, Limitaciones y Casos de Uso Reales

Ventajas

- Capacidad para identificar relaciones complejas entre variables.
- Buena capacidad predictiva en problemas de clasificación.
- Puede adaptarse a grandes volúmenes de datos.
- Excelente desempeño con datos médicos y clínicos.

Limitaciones

- Menor interpretabilidad respecto a modelos tradicionales.
- Requiere mayor capacidad computacional.
- Sensible a la selección de hiperparámetros.
- Puede presentar sobreajuste si no se controla adecuadamente.

Casos de Uso Reales

- Predicción de enfermedades cardiovasculares.
- Diagnóstico asistido por inteligencia artificial.
- Sistemas de apoyo para toma de decisiones médicas.
- Detección temprana de pacientes de alto riesgo.

8. IMPLEMENTACIÓN

8.1. Librerías Utilizadas:

- Pandas
- NumPy
- Matplotlib
- Seaborn
- TensorFlow
- Keras
- Scikit-Learn
- XGBoost
- Imbalanced-Learn
- Missingno

8.2. Hiperparámetros Elegidos:

- Red Neuronal Artificial

8.3. Decisiones de Diseño:

- Se utilizó ReLU para mejorar la velocidad de entrenamiento.
- Se empleó Sigmoid debido a la naturaleza binaria del problema.
- Se aplicó SMOTE para corregir el desbalance de clases.
- Se incorporó EarlyStopping para evitar sobreajuste.

9. MODELO COMPARATIVO

Además de la Red Neuronal Artificial, se implementó un modelo XGBoost con el objetivo de comparar el rendimiento de ambos enfoques.


XGBoost es uno de los algoritmos más utilizados en problemas de clasificación con datos tabulares debido a su alto rendimiento y capacidad de interpretación mediante importancia de variables.

10. RESULTADOS


10.1. F1-score & Accuracy

	precision	recall	f1-score	support
0	0,96	0,86	0,91	972
1	0,12	0,36	0,18	50
accuracy			0,83	1022
macro				
avg	0,54	0,61	0,54	1022
weighted	0,92	0,83	0,87	1022

10.2. matriz de confusión



10.3. Curva ROC




11. ANÁLISIS E INTERPRETACIÓN

Los resultados obtenidos muestran que ambos modelos lograron identificar patrones relevantes asociados al riesgo de accidente cerebrovascular.

La Red Neuronal Artificial alcanzó un ROC-AUC de 0.8538, indicando una buena capacidad para diferenciar pacientes con y sin riesgo de stroke.

El análisis de la matriz de confusión muestra que el modelo logró detectar correctamente la mayoría de los casos positivos, manteniendo un bajo número de falsos negativos, aspecto especialmente importante en aplicaciones médicas.

Al comparar ambos modelos, se evaluaron Accuracy, Recall, F1-Score y ROC-AUC para determinar cuál presenta un mejor equilibrio entre precisión y capacidad de detección.



	Modelo	Accuracy	Precision (Stroke)	Recall (Stroke)	F1-Score (Stroke)	ROC-AUC
0	Red Neuronal (MLP)	0.834638	0.116129	0.36	0.175610	0.609527
1	Random Forest	0.881605	0.091954	0.16	0.116788	0.763374
2	XGBoost	0.890411	0.112500	0.18	0.138462	0.766337

12. CONCLUSIONES

- Se desarrolló exitosamente un sistema de predicción de riesgo de accidente cerebrovascular utilizando variables clínicas y demográficas.
- El preprocesamiento de datos permitió mejorar significativamente la calidad de la información utilizada por los modelos.
- La Red Neuronal Artificial demostró una adecuada capacidad para identificar pacientes con riesgo de stroke.
- El uso de SMOTE contribuyó a reducir el impacto del desbalance de clases.

- La edad, el nivel promedio de glucosa, la hipertensión y las enfermedades cardíacas mostraron una influencia importante en la predicción.

12.1. Limitaciones

- Dataset relativamente pequeño.
- Fuerte desbalance inicial de clases.
- Limitaciones en la disponibilidad de variables clínicas más específicas.

12.2. Posibles Mejoras

- Optimización de hiperparámetros.
- Uso de técnicas avanzadas de Deep Learning.
- Incorporación de datasets clínicos más extensos.
- Implementación de validación cruzada.

13. Bibliografía

Aggarwal, C. C. (2018). *Neural Networks and Deep Learning*. Cham, Suiza: Springer.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Nueva York, Estados Unidos: Springer.

Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, . . . Édouard Duchesnay. (2011). Scikit-Learn: Machine Learning in Python. *Journal of Machine Learning Research*, 2825–2830.

Fedesoriano. (2021). *kaggle*. Obtenido de Stroke Prediction Dataset:
<https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>

Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. Sebastopol, California, Estados Unidos: O'Reilly Media.

Ian Goodfellow, Yoshua Bengio, & Aaron Courville. (2016). *Deep Learning*. Cambridge, Massachusetts, Estados Unidos: MIT Press.